

DATA SCIENCE II


Diego Adolfo Godoy
Comisión 86415

PROYECTO FINAL

Machine Learning aplicado a Mantenimiento Predictivo

NASA Turbofan Jet Engine Dataset

Estimación de Vida Útil Restante con Regresión, Random Forest y XGBoost



Contexto del Negocio

El problema detrás del proyecto



Mantenimiento Correctivo

Fallas inesperadas generan paradas no planificadas, altos costos de reparación y riesgo operativo.



Mantenimiento Preventivo

Intervenciones fijas sin considerar el estado real del equipo. Genera costos innecesarios.



Mantenimiento Predictivo

Anticipa fallas usando datos históricos y sensores en tiempo real. Reduce costos y mejora eficiencia.



El mantenimiento predictivo reduce hasta un 30% los costos operativos y elimina paradas no planificadas.

Objetivo del Proyecto y Dataset

NASA Turbofan Jet Engine Data Set



Objetivo General

Desarrollar un modelo que permita estimar la Vida Útil Restante de motores turbofan a partir de datos de sensores, anticipar fallas y optimizar la toma de decisiones en mantenimiento.

Objetivos Específicos

-  Analizar comportamiento de sensores a lo largo del tiempo
-  Detectar patrones de degradación en los motores
-  Identificar variables relevantes para la predicción
-  Construir variable objetivo: Vida Útil Restante
-  Preparar datos y entrenar modelos de ML



Dataset

NASA Turbofan Jet Engine Data Set (FD001)



20.631

Registros totales



100

Motores simulados



21

Sensores por motor




3

Configuraciones operativas

Fuente: Kaggle / NASA CMAPS · Tipo: Regresión continua

Data Wrangling e Ingeniería de Variables

Preparación y limpieza del dataset



Vida_util = ciclo_max – ciclo_actual → Variable objetivo de regresión continua

Análisis Exploratorio — Hallazgos Clave

Patrones de degradación en sensores



Degradación Progresiva

La vida útil disminuye de forma consistente a medida que aumenta el número de ciclos.



Sensores Predictivos

Sensores específicos muestran variaciones sistemáticas previas a la falla del motor.



Alta Correlación

Varios sensores presentan alta correlación con la vida útil restante.



Patrones Repetitivos

Los patrones de desgaste se repiten en distintos motores, lo que permite generalizar.

TOP SENSORES CON MAYOR CORRELACIÓN CON VIDA ÚTIL

sensor_11

-0.847

sensor_4

-0.821

sensor_12

-0.813

sensor_15

+0.798

sensor_7

-0.771

Modelos de Machine Learning

Regresión, Random Forest y XGBoost

Estrategia de Modelado

01 Regresión Lineal

Configuración:

Modelo base (baseline).
Captura relaciones lineales entre sensores y vida útil.

Ventaja:

Interpretabilidad alta. Referencia para comparar.

02 Random Forest

Configuración:

100 árboles de decisión.
Captura relaciones no lineales y reduce el sobreajuste.

Ventaja:

Mayor robustez.
Maneja outliers naturalmente.

03 RF Optimizado (GridSearchCV)

Configuración:

Búsqueda de mejores hiperparámetros:
n_estimators, max_depth, min_samples_split.

Ventaja:

Maximiza R^2 con validación cruzada cv=3 folds.

04 XGBoost

Configuración:

Gradient Boosting con 200 estimadores.
learning_rate=0.05, max_depth=6.

Ventaja:

Alto rendimiento predictivo en datos industriales.



Train/Test Split 80/20 · StandardScaler para regresión lineal · Validación cruzada 5-fold en todos los modelos

Resultados Comparativos de Modelos

Métricas de evaluación: RMSE · MAE · R²

Modelo	RMSE ↓	MAE ↓	R² ↑	Ranking
Random Forest Optimizado	35.62	25.27	0.7223	 1°
XGBoost	35.64	25.37	0.7221	 2°
Random Forest	35.93	25.45	0.7174	 3°
Regresión Lineal	39.70	30.54	0.6550	4°




MEJOR MODELO: Random Forest Optimizado

RMSE: 35.62 · MAE: 25.27 · R²: 0.722

Explica el 72%
de la variabilidad

Importancia de Variables — Feature Importance

Top variables del modelo Random Forest Optimizado



* El ciclo acumulado y los sensores relacionados a temperatura y presión son los predictores más relevantes.

Validación del Modelo y Capacidad de Generalización

Cross-Validation 5-Fold · Resultados consistentes



Validación Cruzada — R² por Fold



Conclusiones de Validación

- Resultados estables entre folds ($\sigma < 0.015$), indicando baja varianza del modelo.
- R² promedio de 0.722 confirma la capacidad predictiva del modelo optimizado.
- No se observan señales de sobreajuste (overfitting).
- El modelo generaliza bien ante datos no vistos durante el entrenamiento.
- GridSearchCV con cv=3 fue usado para la optimización de hiperparámetros.

Modelo listo para producción con confianza estadística validada.

Resultados del Proyecto



Conclusiones

- ✓ Se construyó exitosamente una variable objetivo (Vida Útil Restante) que refleja el desgaste real de los motores.
- ✓ El modelo Random Forest Optimizado alcanzó $R^2 = 0.722$, explicando el 72% de la variabilidad.
- ✓ Los modelos basados en árboles superaron a la regresión lineal, capturando relaciones no lineales.
- ✓ La validación cruzada confirma buena capacidad de generalización sin sobreajuste.
- ✓ El ciclo acumulado y sensores de temperatura/presión son los predictores más relevantes.



Próximos Pasos

Corto plazo

Aplicar modelo a datos FD002–FD004 (múltiples condiciones operativas).

Mediano plazo

Implementar modelo en pipeline de datos en tiempo real con sensores.

Objetivo real

Adaptar metodología a baterías UPS en entornos industriales críticos.

Mejoras ML

Explorar LSTM / Deep Learning para series temporales de sensores.